

Institut International de Technologie  
Cours Théorie des langages & automates

# Introduction aux langages



INTERNATIONAL  
INSTITUTE OF  
TECHNOLOGY

North American Private University

Soufiene.Lajmi@gmail.com

Année universitaire 2020-2021

## Plan

- (I) Introduction et concepts fondamentaux
- (II) Les langages réguliers et les expressions régulières
- (III) Les grammaires
- (IV) Les automates

**Evaluation= 30%CC + 70% Examen final**

# **Chapitre 1**

## **Introduction et concepts fondamentaux**

3

### **Sommaire**

**Alphabet, mots et langage**

**Opérations sur les mots**

**Structure de monoïde**

**Opérations sur les langages**

4

## Alphabet, mots et langage

- Définition d'un alphabet :
  - Un **alphabet** est un ensemble fini d'éléments appelés **symboles** (ou **lettres**).
  - Exemples de symboles et d'alphabet :
    - Lettres (minuscules et majuscules) : a, b, ... z, A, B, ..., Z.
    - Chiffres décimaux : 0, 1, ..., 9
    - Les caractères du clavier.
    - Alphabet des nombres binaires : {0, 1}.
    - Alphabet informatique : ASCII et EBCDIC.

5

## Alphabet, mots et langage

- Exemples de symboles et d'alphabet (suite) :
  - Alphabet des nombres octaux : {0, 1, ..., 7}.
  - Alphabet des nombres hexadécimaux : {0, 1, ..., 9, a, b, c, d, e, f, A, B, C, D, E, F}.
  - Alphabet Français : {a, A, b, B, ..., z, Z}.
  - Alphabet des identificateurs du langage C : {a, b, ..., z, A, B, ..., Z, 0, 1, ..., 9, \_}.
  - Alphabet des nombres entiers décimaux en C : {+, -, 0, 1, ..., 9}.
- Remarque : l'alphabet vide ne contient aucun symbole.

6

## Alphabet, mots et langage

- Définition d'un mot sur un alphabet :
  - Un **mot**  $s$  sur un alphabet A est une séquence finie de symboles de A.
  - Les symboles faisant partie d'un mot  $s$  s'écrivent juxtaposés l'un à l'autre de gauche à droite.
  - La **longueur d'un mot**  $s$  sur l'alphabet A est le nombre des symboles constituants le mot  $s$ . Elle est notée indifféremment par  $|s|$  ou  $lg(s)$ .
  - Sur tout alphabet A, on peut définir un mot spécial : le mot vide noté  $\varepsilon$ . sa longueur est 0 ( $|\varepsilon| = 0$ ). On a :  $|s| = 0$ , si et seulement si  $s = \varepsilon$ .

7

## Alphabet, mots et langage

- Exemples de mots sur des alphabets :
  - $s = \text{aller}$  est un mot sur l'alphabet Français.  $|s| = ?$ .
  - $s = 001$  est un mot sur l'alphabet  $\{0, 1\}$ .  $|s| = ?$ .
  - $s = 11AF0009C$  est un mot sur l'alphabet des nombres hexadécimaux.  $|s| = ?$ .
  - $s = -12.254$  est un mot sur l'alphabet des nombres. On a :  $|s| = ?$ .
- Soit  $s$  un mot de longueur  $n$  sur un alphabet A. Si  $n = 0$ , alors  $s$  est le mot vide ( $s = \varepsilon$ ). Si  $n > 0$ ,  $s$  s'écrit sous la forme  $\alpha_1\alpha_2\dots\alpha_n$  où chaque  $\alpha_i$  est un symbole ( $\alpha_i \in A$ ) pour tout indice  $i$  de 1 à n. On a :  $s = \alpha_1\alpha_2\dots\alpha_n$ .

8

## Alphabet, mots et langage

- Dans un mot  $s = \alpha_1\alpha_2\dots\alpha_n$  de longueur  $n$  sur un alphabet  $A$ ,  $\alpha_i$  s'appelle le **symbole** (ou **terme**) de rang  $i$ .
- Le symbole de rang  $i$  du mot  $s$ , se note par  $s(i)$ .
- Parfois,  $s(i)$  se nomme aussi la «  $i^{\text{ème}}$  lettre de  $s$  ».
- Deux mots  $s = \alpha_1\alpha_2\dots\alpha_n$  et  $t = \beta_1\beta_2\dots\beta_m$  sur un même alphabet  $A$  sont égaux, si et seulement si :
  - $|s| = |t|$  (c'est-à-dire ici,  $n = m$ ).
  - Pour tout  $i$  de  $1$  à  $n$ ,  $s(i) = t(i)$  (c'est-à-dire ici  $\alpha_i = \beta_i$ ).
- Deux mots  $s = \alpha_1\alpha_2\dots\alpha_n$  et  $t = \beta_1\beta_2\dots\beta_m$  sur un même alphabet  $A$  sont différents, si et seulement si  $|s| \neq |t|$  ou il existe un indice  $i$  tel que :  $s(i) \neq t(i)$ .

9

## Alphabet, mots et langage

- Définition d'un langage sur un alphabet :
  - Un **langage**  $L$  sur un alphabet  $A$  est un ensemble de mots sur  $A$ .
- Exemples :
  - $L = \{0, 10, 101\}$  est un langage sur l'alphabet  $\{0, 1\}$ .
  - $V = \{1, 01, 11, 001, 011, 101, 111, 0001, 0011, 0101, 0111, \dots\}$  est le langage de tous les mots sur  $\{0, 1\}$  se terminant par un « 1 ».
- Remarque :
  - Un langage sur un alphabet  $A$  peut être vide, fini ou infini.

10

## Alphabet, mots et langage

- Certains langages particuliers sur un alphabet A donné :
  - Un alphabet A est un langage sur A. En fait, un symbole est considéré comme un mot de longueur 1.
  - L'ensemble vide  $\emptyset$  est un langage sur A.
  - $\{\epsilon\}$  l'ensemble formé par le mot vide est aussi un langage sur A. Attention,  $\{\epsilon\} \neq \emptyset$ .
  - L'ensemble formé par tous les mots possibles sur l'alphabet A est un langage sur A. Ce langage très important est noté par  $A^*$ .
  - $A^*$  s'appelle le **monoïde libre** sur A.

11

## Alphabet, mots et langage

- Exemples du monoïde libre  $A^*$  sur A :
  - Si  $A = \emptyset$  (alphabet vide), alors  $A^* = \{\epsilon\}$ .
  - Si  $A = \{\epsilon\}$  (alphabet formé par le symbole vide), alors  $A^* = \{\epsilon\}$ .
  - Si  $A = \{a\}$  (alphabet à un seul symbole), alors  $A^* = ?$
  - Si  $A = \{0, 1\}$  (alphabet binaire), alors  $A^* = ?$ .
- Propriétés de base du langage  $A^*$  :
  - $A^*$  n'est jamais vide. En effet, on a toujours  $\epsilon \in A^*$ .
  - $A \subset A^*$ .

12

## Alphabet, mots et langage

- $A^* = \{\epsilon\}$  si et seulement si  $A = \emptyset$  ou  $A = \{\epsilon\}$ .
- $A^*$  est infini dès que  $A$  contient au moins un symbole (qui ne soit pas le symbole vide).
- Tout langage  $L$  sur un alphabet  $A$  est une partie de l'ensemble de  $A^*$ :  $L$  est un langage sur l'alphabet  $A$ , si et seulement si  $L \subset A^*$ .
- Un mot  $s$  sur l'alphabet  $A$  est simplement un élément de l'ensemble  $A^*$ .

13

## Alphabet, mots et langage

- Définition d'un langage formel:
  - C'est tout sous ensemble de  $A^*$  dont les mots peuvent être définis de deux façons conformément à:
  - Définition par propriété: il s'agit d'une modélisation formelle d'une description naturelle d'un langage.
    - Exemple  $L1 = \{\text{ensemble des mots définis sur } \{a,b\} \text{ de longueur paire}\}$   
 $L1 = \{w \in \{a,b\}^* / |w| = 2n \text{ avec } n \geq 0\}$
  - Définition récursive : Définition dans laquelle, un langage est défini sur lui même.
  - Exemple:
  - $L2 = \{w \in A^* / w = a \text{ ou } w = aw_1 ; w_1 \in L2\}$   
 $= \{a, aa, \dots, aaaa, \dots\}$
  - $L3 = \{w \in A^* / w = \epsilon \text{ ou } w = w_1w_2 \text{ avec } |w_1| = 2 \text{ et } w_2 \in L3\}$
  - $L3 \equiv L1$

14

## Opérations sur les mots

- **Concaténation (collage, jointure) :**
  - Soit  $s$  et  $t$  deux mots sur un même alphabet  $A$ .
  - La concaténation de  $s$  et  $t$  est le mot obtenu en écrivant d'abord les symboles de  $s$ , suivis ensuite par les symboles de  $t$ .
  - Formellement, si  $s = \alpha_1\alpha_2\dots\alpha_n$  et  $t = \beta_1\beta_2\dots\beta_m$  alors, la concaténation de  $s$  et de  $t$ , notée «  $st$  » donne le mot suivant :  $st = \delta_1\delta_2\dots\delta_{n+m}$  où :
    - $\delta_i = \alpha_i$  pour tout indice  $i$  de 1 à  $n$ .
    - $\delta_i = \beta_{i-n}$  pour tout indice  $i$  de  $n+1$  à  $n+m$ .

15

## Opérations sur les mots

- Exemple :
  - Soit les mots  $s = 01$  et  $t = 11$  sur  $A = \{0, 1\}$ . Alors, la concaténation de  $s$  et  $t$  est  $st = ?$ .
  - La concaténation de  $t$  et  $s$  est  $ts = ?$ .
- Propriétés de la concaténation :
  - **Associativité** :  $(st)u = s(tu) = stu$ .
  - **Élément neutre** :  $\epsilon s = s\epsilon = s$ , pour tout mot  $s$  sur  $A$ .
  - $|st| = |s| + |t|$ .
  - **Non commutative** (en général) :  $st \neq ts$ .
  - $|st| = 0$  si et seulement si  $s = t = \epsilon$ .

16

## Opérations sur les mots

- **Puissance :**

- Soient  $s$  un mot sur un alphabet  $A$  et  $n$  un entier naturel.
- La puissance  $n^{\text{ème}}$  de  $s$ , notée  $s^n$ , est définie de façon récursive par :
  - $s^0 = \epsilon$ .
  - $s^n = s^{n-1}s$ , pour  $n \geq 1$
- Exemple :
  - Soient  $s = aba$  un mot sur l'alphabet  $A = \{a, b\}$ . Alors,  $s^2 = abaaba$ ,  $s^3 = abaabaaba$ .

17

## Opérations sur les mots

- **Propriétés de la puissance :**

- Soit  $A$  un alphabet. On montre facilement les propriétés suivantes :
  - $\forall s \in A^* : s^0 = \epsilon$  et  $s^1 = s$ .
  - $\forall s \in A^*, \forall n, m \in N : s^n s^m = s^{n+m}$ .
  - $\forall s \in A^*, \forall n, m \in N : (s^n)^m = s^{nm}$
  - $\forall s \in A^*, \forall n \in N : |s^n| = n|s|$ .

18

## Opérations sur les mots

- Miroir (renversé) :
  - Soit A un alphabet et u un mot sur A.
  - Le miroir (ou le renversé) de u est le mot obtenu à partir de u en inversant les lettres de celui-ci.
  - Le miroir d'un mot u est noté par  $u^R$  ou  $\tilde{u}$ .
  - Exemple :
    - le miroir du mot u = abab sur l'alphabet A = {a, b} est  $\tilde{u}$  = baba.
  - Un mot u sur A est un **palindrome** si et seulement si u est identique (égal) à son miroir  $\tilde{u}$  ( $u = \tilde{u}$ ).

19

## Opérations sur les mots

- Exemples :
  - 101 est un palindrome sur l'alphabet A = {0, 1}.
  - abcba est un palindrome sur A = {a, b, c}.
  - Quelques palindromes Français :
    - radar.
    - non.
    - alla, ressasser.
    - elle, été.
    - ici.
    - tôt, ses.

20

## Opérations sur les mots

- **Propriétés du miroir :**

- Soit A un alphabet. On montre facilement les propriétés suivantes :
  - $\forall u, v \in A^* : (uv)^R = v^R u^R$ .
  - $\forall u \in A^* : (u^R)^R = u$  (le miroir est involutif).
  - $\forall s \in A^* : |s^R| = |s|$  (le mot et son miroir ont la même longueur).

21

## Opérations sur les mots

- **Préfixes, suffixes, facteur:**

- Soient A un alphabet et s un mot sur A.
- On dit qu'un mot u sur A est un **préfixe** de s si et seulement si il existe un mot v sur A tel que  $s = uv$ .
- On dit qu'un mot v sur A est un **suffixe** de s si et seulement si il existe un mot u sur A tel que  $s = uv$ .
- On dit qu'un mot w sur A est un **facteur** de s si et seulement si il existe deux mots u et v sur A tels que  $s = uwv$ .

22

## Opérations sur les mots

- Exemples : soit le mot  $s = abbba$  sur  $A = \{a, b\}$ .
  - Les préfixes de  $s$  sont :  $\epsilon, a, ab, abb, abbb$  et  $abbba$ .
  - Les suffixes de  $s$  sont :  $\epsilon, a, ba, bba, bbba$  et  $abbba$ .
  - Les facteurs de  $s$  sont :  $\epsilon, a, b, ab, bb, ba, abb, bbb, bba, abbb, bbba$  et  $abbba$ .
- Remarque :
  - $\epsilon$  et  $s$  sont des préfixes, des suffixes et des facteurs de  $s$ .

23

## Opérations sur les mots

- On appelle **préfixe** (resp. **suffixe** ou **facteur**) **propre** d'un mot  $s$  un préfixe (resp. suffixe ou facteur) différent de  $\epsilon$  et  $s$ .
- Exemples :
  - Les préfixes propres de  $s$  sont :  $a, ab, abb$  et  $abbb$ .
  - Les suffixes propres de  $s$  sont :  $a, ba, bba$  et  $bbba$ .
  - Les facteurs propres de  $s$  sont :  $a, b, ab, bb, ba, abb, bbb, bba, abbb$  et  $bbba$ .

24

## Structure de monoïde

- En algèbre, un **monoïde** est un ensemble  $M$  muni d'une loi de composition interne  $*$  (c'est-à-dire une application de  $M \times M$  vers  $M$ ) qui :
  - soit associative :  $(x * y) * z = x * (y * z)$ .
  - admet un élément neutre  $e$  :  $x * e = e * x = x$ .
- Exemples :
  - $(N, +, 0)$  est un monoïde.
  - $(N, \times, 1)$  est un monoïde.
  - Tout groupe  $(G, *, e)$  est un monoïde.  
-  $(A^*, \circ, \epsilon)$   
↑  
concat

25

## Structure de monoïde

- Théorème 1 :
- L'ensemble de tous les mots sur un alphabet  $A$  est un monoïde pour l'opération de la concaténation des mots.
- Cet ensemble s'appelle le **monoïde libre** sur  $A$  et nous l'avons noté par  $A^*$ .
- On note  $A^+$  l'ensemble des mots non vides sur  $A$  :  $A^+$  est donc  $A^* \setminus \{\epsilon\}$ .
- Exemple :
  - pour  $A = \{a\}$ ,  $A^+ = \{a, aa, aaa, aaaa, \dots\}$ .
  - pour  $A = \{a, b\}$ ,  $A^+ = \{a, b, aa, ab, ba, bb, \dots\}$ .

26

## Opérations sur les langages

- Soient A un alphabet et L et M deux langages sur A.
- On peut définir les opérations suivantes :
  - L'**intersection** de L et M :  $L \cap M$  est formé par tous les mots sur A appartenant simultanément à L et à M.
  - La **réunion** de L et M :  $L \cup M$  est formé par tous les mots sur A appartenant à L ou à M (noté aussi  $L+M$ ).
  - La **concaténation** de L et M :  $LM$  est formé par tous les mots sur A, obtenus en concanétant tous les mots de L avec tous les mots de M.
  - La **fermeture de Kleene** (ou l'**étoile**) de L :  $L^*$  est formé par tous les mots sur A qui sont des puissances de mots de L.

27

## Opérations sur les langages

- La **fermeture de Kleene positive** (ou l'**étoile positive**) de L :  $L^+$  est formé par tous les mots sur A qui sont des puissances non nulles de mots de L.
- La **complémentation** de L :  $\bar{L}$  est formé par tous les mots sur A n'appartenant pas à L.
- Formellement :
  - $L \cap M = \{s \in A^* \mid s \in L \text{ et } s \in M\}$ .
  - $L + M = L \cup M = \{s \in A^* \mid s \in L \text{ ou } s \in M\}$ .
  - $LM = \{s \in A^* \mid \exists u \in L, \exists v \in M : s = uv\}$ .
  - $L^* = \{s \in A^* \mid \exists u_1, \dots, u_n \in L : s = u_1 \dots u_n\} \cup \{\epsilon\}$
  - $L^+ = L^* \setminus \{\epsilon\}$ .

28

## Opérations sur les langages

- $\bar{L} = \{s \in A^* \mid s \notin L\}$ .
- On note  $L^n$  l'ensemble formé par les puissances  $n^{\text{ème}}$  des mots appartenant à  $L$  (appelé **puissance  $n^{\text{ème}}$  de  $L$** ).
- Quelques propriétés importantes :
  - L'intersection et la réunion sont commutatives, associatives et distributives, l'une par rapport à l'autre.
  - $L^0 = \{\epsilon\}$  et  $L^1 = L$ ,  $L^2 = LL$ , et ainsi de suite.
  - $L^* = L^0 \cup L^1 \cup L^2 \cup L^3 \cup \dots$
  - $L^+ = L^1 \cup L^2 \cup L^3 \cup \dots$
  - $(LM)N = L(MN)$

29

## Opérations sur les langages

- $L\{\epsilon\} = \{\epsilon\}L = L$ .
- $L(M + N) = LM + LN$ .
- $L(M \cap N) = (\text{inclu})LM \cap LN$ .
- On peut aussi définir le **miroir d'un langage**  $L$  comme étant formé par les miroirs des mots appartenant à  $L$ . On obtient alors un autre langage, noté  $L^R$ . Formellement :  $L^R = \{s^R \mid s \in L\}$ .
- On a les propriétés suivantes :
  - $(L^R)^R = L$ .
  - $(LM)^R = M^R L^R$ .
  - $(L + M)^R = L^R + M^R$  et  $(L \cap M)^R = L^R \cap M^R$ .

30

## Opérations sur les langages

- $C^+$  : langage des mots d'au moins un chiffre.
- Remarque :
  - Toutes les unités lexicales d'un langage de programmation peuvent être décrites en utilisant les trois opérations suivantes :
    - La concaténation.
    - La réunion.
    - La fermeture de Kleene.
  - Exemple :  $L(L + C)^*$  est l'ensemble de tous les identificateurs en Pascal.